1. INTRODUÇÃO

Este trabalho tem como objetivo implementar e analisar dois modelos de machine learning do tipo supervisionado, o modelo clássico de Naive Bayes e a rede neural Multi Layer Perceptron(MLP) aplicados a duas bases de dados, uma com duas classes target e a outra com 7 classes target. Após aplicar os modelos em ambas as bases será feita uma análise através das métricas de cada modelo com o intuito de verificar qual dos algoritmos tiveram um melhor desempenho em cada base.

2. REFERENCIAL TEÓRICO

Existem três tipos principais de aprendizado de máquina, o supervisionado, não supervisionado e por reforço. Tanto o modelo de Naive Bayes e o Multi Layer Perceptron utilizam o tipo supervisionado, neste o algoritmo recebe dados de entrada e possuí os resultados das classes target, funcionando como um gabarito, os principais problemas abordados por esse tipo de aprendizado são o de classificação e regressão. O problema de classificação tem como objetivo prever a qual classe um determinado dado de entrada pertence, enquanto que o problema de regressão serve para deduzir um valor numérico contínuo, neste trabalho trataremos do problema de classificação em ambas as bases.

O algoritmo de Naive Bayes é fundamentado no Teorema de Bayes, desenvolvido a partir da teoria das probabilidades. Seu funcionamento consiste em calcular a probabilidade de uma determinada amostra pertencer a cada uma das classes possíveis, considerando as características presentes nos dados de entrada. Para isso, o algoritmo utiliza as probabilidades condicionais, que representam a chance de um evento ocorrer sabendo que outro evento já ocorreu. Sua principal premissa é a independência condicional entre os atributos, ou seja, considera que as características são independentes entre si quando a classe da amostra é conhecida. Essa simplificação dá origem ao termo Naive.

O conceito de neurônio artificial foi inicialmente apresentado por Warren McCulloch e Walter Pitts, em 1943, em um modelo matemático inspirado no funcionamento dos neurônios biológicos. Nesse modelo, um neurônio artificial(figura 1) recebe valores de entrada, representados por x_i, aos quais são associados pesos w_i , que determinam a influência de cada entrada no resultado. Esses valores são multiplicados pelos respectivos pesos e somados, adicionando também um termo de viés, bias. O resultado dessa operação é encaminhado para uma função de ativação, responsável por determinar a saída do neurônio. Essa função introduz não linearidade ao modelo, permitindo que a rede aprenda relações mais complexas entre os dados.

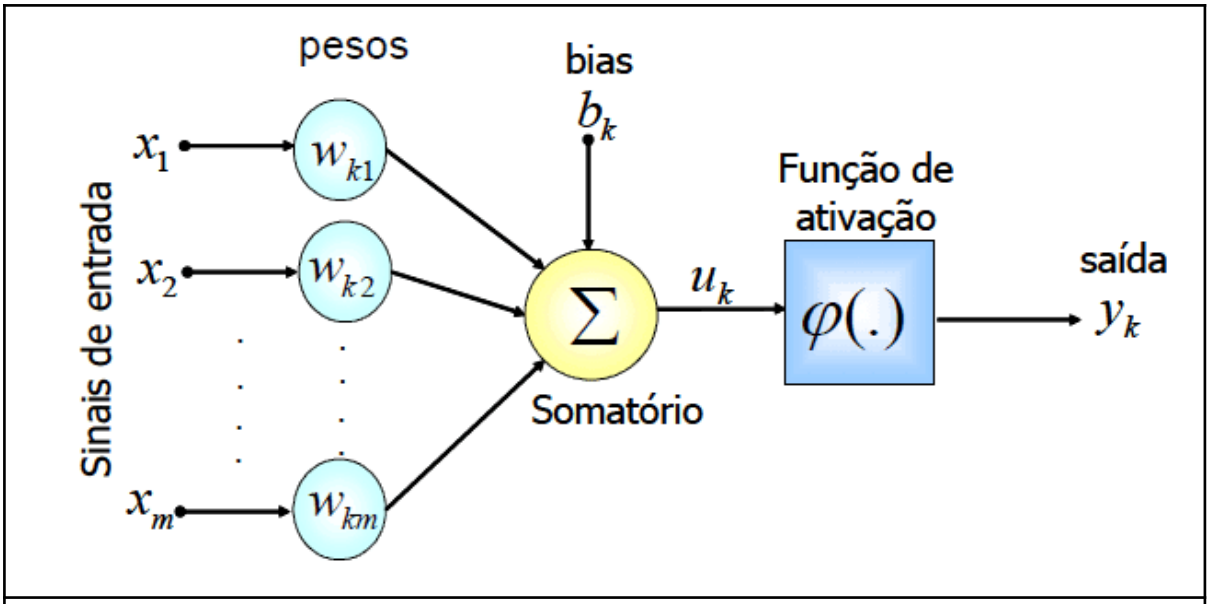


Figura 1: Representação de um neurônio artificial.

Inicialmente, o modelo Perceptron de camada única (Single-Layer Perceptron — SLP) utilizava uma estrutura composta por uma camada de entrada e uma camada de saída, sem camadas intermediárias. Embora seja capaz de solucionar determinados problemas de classificação, sua capacidade é limitada a problemas linearmente separáveis. Com o objetivo de ampliar essa capacidade, foram desenvolvidas arquiteturas com múltiplas camadas, dando origem ao Multi Layer Perceptron. Nesse modelo, são adicionadas uma ou mais camadas ocultas (hidden layers) de neurônios. Cada camada é composta por neurônios artificiais que recebem os resultados da camada anterior, realizam suas operações e encaminham as saídas para a próxima camada. A utilização de múltiplas camadas e funções de ativação não lineares permite ao MLP aprender padrões mais complexos.

O funcionamento de um MLP ocorre por meio de dois processos principais, feedforward e backpropagation. No feedforward, os dados de entrada percorrem a rede camada por camada, passando pelas operações de multiplicação pelos pesos, somatório e aplicação das funções de ativação, até que seja produzida uma saída. Em seguida, durante o treinamento, essa saída é comparada com o resultado esperado, permitindo calcular o erro cometido pela rede. É nesse momento que ocorre o backpropagation, processo responsável por propagar esse erro no sentido inverso do feedfoward, por meio do gradiente da função do erro. Esses gradientes indicam como os pesos devem ser ajustados para reduzir o erro. Dessa forma, os pesos são atualizados iterativamente, melhorando a resposta gerada pela rede neural.

3. METODOLOGIA

3.1 Bases de Dados

Para avaliar o desempenho dos modelos propostos, foram utilizadas duas bases de dados públicas:

- **Base 1 (Classificação Binária - Imagens):** Dataset Cats and Dogs. o pré-processamento consistiu em padronizar o espaço de cores (removendo o canal alfa de imagens RGBA ou empilhando canais em imagens em tons de cinza para forçar o formato RGB). As imagens foram redimensionadas (para 32x32 pixels no MLP e 64x64 no Naive Bayes) e, em seguida, as matrizes tridimensionais foram achatadas em vetores unidimensionais para servirem como entrada.
- **Base 2 (Classificação Multiclasse - Dados Tabulares):** Dry Bean Dataset, contendo características geométricas extraídas de grãos de feijao. A base possui 16 atributos numéricos contínuos (Como Area, Perimeter, ConvexArea, Compactness, etc) e o objetivo é classificar as instâncias em uma das 7 classes distintas, as quais foram mapeadas numericamente (SEKER = 0, BARBUNYA = 1, BOMBAY = 2, CALI = 3, DERMASON = 4, HOROZ = 5, SIRA = 6).

3.2 Ferramentas e bibliotecas

O desenvolvimento dos scripts foi realizado na linguagem Python. Para a manipulação, leitura de matrizes e organização dos dados, utilizou-se as bibliotecas Pandas e NumPy. As matrizes de confusão foram geradas via Matplotlib. A implementação dos algoritmos de Machine Learning, bem como o cálculo das métricas de desempenho, foram realizados através da biblioteca Scikit-Learn.

3.3 Divisão dos Dados e Padronização

Para a base Cats and Dogs, os dados já foram fornecidos previamente particionados, sendo lidos e processados a partir de arquivos distintos para treinamento e validação. Já para a base Dry Bean, a divisão ocorreu utilizando a função train_test_split, destinando 80% das instâncias para o treinamento do modelo e 20% para teste, com a semente aleatória fixada em 42, para assegurar a reprodutibilidade do experimento.

Como o algoritmo Multi Layer Perceptron (MLP) realiza o ajuste de pesos com base no gradiente descendente, ele é altamente sensível à escala dos dados (SCIKIT-LEARN, 2026). Por isso, os atributos de entrada de ambas as bases foram padronizados através da classe StandardScaler, que reescala os dados para que possuam média zero e variância um.

3.4 Configuração dos Modelos

A definição dos hiperparâmetros para ambos os classificadores ocorreu de forma empírica. Diferentes configurações foram testadas. Os parâmetros finais foram escolhidos com base naqueles que apresentaram o melhor equilíbrio entre desempenho e custo computacional durante os testes.

- **Multi Layer Perceptron (MLP):** O modelo MLPClassifier foi instanciado com duas camadas ocultas, contendo 100 e 50 neurônios, respectivamente. A funçao de ativaçao definida para as camadas ocultas foi a ReLU (Rectified Linear Unit), com limite máximo de iterações fixado em 300, o que significa que a rede executou o ajuste de pesos com um teto de no máximo 300 épocas sobre o conjunto de treinamento.
- **Naive Bayes:** Optou-se pelo modelo Gaussiano (GaussianNB), adequado para tratar variáveis contínuas (como os pixels padronizados e os atributos geométricos dos feijões). Para a base Dry Bean, após os testes, aplicou-se um fator de suavização da variância (var_smoothing) ajustado para 1×10^{-1}, visando evitar instabilidades numéricas e melhorar a precisão do cálculo probabilístico.

3.5 Métricas de Avaliação

O desempenho dos classificadores foi mensurado através da Acurácia, Precisão, Recall e F1-Score. Adicionalmente, gerou-se o Relatório de Classificação e a Matriz de Confusão para visualizar a taxa de falsos positivos e negativos.

4. RESULTADOS

Os resultados são referentes aos melhores ajustes de hiperparâmetros em cada modelo, utilizando como comparação as métricas de acurácia, precisão, recall e F1-Score.

Tabela 1 - Métricas Gerais de Cada Modelo					
Dataset	**Modelo**	**Acurácia**	**Precisão**	**Recall**	**F1-Score**
Cats and Dogs	Naive Bayes	0.60	0.69	0.72	0.70
Cats and Dogs	MLP (Rede Neural)	0.57	0.67	0.67	0.67
Dry Beans	Naive Bayes	0.89	0.89	0.89	0.89
Dry Beans	MLP (Rede Neural)	0.93	0.93	0.93	0.93

Tabela 2 - Métricas de Cada Classe em Dry Beans(Naive Bayes)				
Classe	**Precision**	**Recall**	**F1-Score**	**Support**
BARBUNYA	0.94	0.94	0.94	413
BOMBAY	0.85	0.71	0.77	261

Tabela 2 - Métricas de Cada Classe em Dry Beans(Naive Bayes)				
CALI	1.00	1.00	1.00	117
DERMASON	0.81	0.90	0.85	317
HOROZ	0.92	0.87	0.89	671
SEKER	0.95	0.95	0.95	408
SIRA	0.82	0.89	0.85	536

Tabela 3 - Métricas de Cada Classe em Dry Beans(MLP)				
Classe	**Precision**	**Recall**	**F1-Score**	**Support**
BARBUNYA	0.92	0.93	0.93	261
BOMBAY	1.00	1.00	1.00	117
CALI	0.93	0.95	0.94	317
DERMASON	0.88	0.96	0.92	671

Tabela 3 - Métricas de Cada Classe em Dry Beans(MLP)				
HOROZ	0.98	0.93	0.95	408
SEKER	0.97	0.93	0.95	413
SIRA	0.90	0.86	0.88	536

Tabela 4 - Métricas de Cada Classe em Cats_Dogs(Naive Bayes e MLP)					
Classe	**Modelo**	**Precision**	**Recall**	**F1-Score**	**Support**
0	**Naive Bayes**	0.41	0.38	0.39	24
0	**MLP (Rede Neural)**	0.38	0.38	0.38	24
1	**Naive Bayes**	0.69	0.72	0.70	46
1	**MLP (Rede Neural)**	0.67	0.67	0.67	46

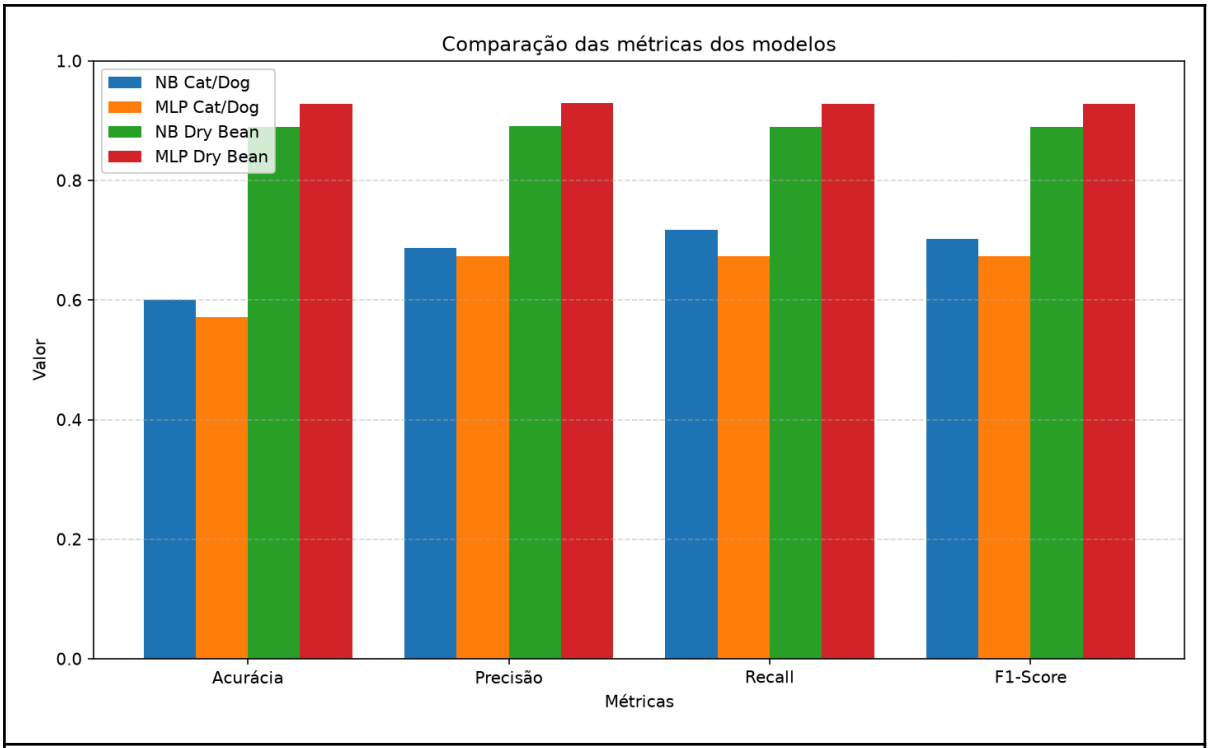


Figura 2: Gráfico comparando as principais métricas entre modelos e base de dados.

5. CONCLUSÃO

A análise comparativa entre a Rede Neural Artificial (Multilayer Perceptron - MLP) e o Naive Bayes demonstrou que o desempenho de ambos os classificadores varia consideravelmente conforme a natureza e a complexidade dos dados de entrada. No dataset tabular Dry Bean, a arquitetura MLP obteve o melhor desempenho geral, alcançando uma acurácia de 93% (frente a 89% do Naive Bayes), o que evidencia a maior capacidade das redes neurais em capturar relações não lineares em conjuntos de dados tabulares estruturados e com múltiplas classes. Por outro lado, no dataset Cats and Dogs baseado em características vetoriais extraídas de imagens , ambos os algoritmos apresentaram limitações de desempenho, registrando acurácias próximas de 57% a 60%. Esse comportamento sugere que representações baseadas unicamente no achatamento de pixels sem o uso de convoluções limitam o poder discriminativo de classificadores tradicionais. Desse modo, conclui-se que, embora redes MLP tendem a superar abordagens probabilísticas simples em bases tabulares complexas, a escolha do modelo deve ser rigorosamente alinhada às características estruturais da base de dados avaliada.

6. ÉTICA NO USO DA IA GENERATIVA

A IA foi utilizada na parte do código fonte para verificar possíveis erros e formatação na apresentação de resultados, além de ser utilizada na revisão deste artigo.